

结构变异基因分型的长读比对堆的K-mer分析

收稿日期:2024年10月22日接
受日期:2025年3月25日

Adam C. English¹, Fabio Cunial², Ginger A. Metcalf¹, Richard A. Gibbs^{1,3} & Fritz J. Sedlazeck^{1,3,4} 

Published online: 04 April 2025

 查看最新消息

准确分型结构变异(SV)等位基因对基因组学研究至关重要。我们提出了一种新的SV基因分型方法(kanpig),利用变异图和k-mer载体快速生成准确的SV基因型。针对最新SV数据集的基准测试显示,kanpig实现了82.1%的单样本基因分型一致性,显著优于现有工具的平均水平66.3%。我们通过对47个遗传多样性样本的测试,探索了kanpig在多样本项目中的应用,发现了kanpig准确的基因型复合位点(例如SV与其他SV相邻),并产生了比其他工具更高的基因型一致性。Kanpig只需要43秒就可以处理单个样本的20倍长读,并且可以在PacBio或Oxford Nanopore长读上运行。

越来越多的长读测序技术已经开始应用于群体规模的基因组研究^{1,2}。这是由于样品要求、错误率和运行长读测序仪器的成本的关键改进而成为可能的。利用长读段的生物信息学应用也日趋成熟。这些创新导致了完整基因型变异文件(VCF)的产生,其中包含了样本中每个变异存在的信息。这个VCF为后续的分析提供了基础,如全基因组关联和群体基因组学。虽然对于较小的突变(SNV和indels),创建完全基因型vcf的过程是简化的,但对于结构变异(SV;即大于50个碱基对的基因组改变)。目前最先进的工作流程涉及每个样本的SV发现,然后将其与³muvar⁴等方法合并,然后在所有样本中重新评估每种SV的存在或不存在(即基因分型)。

随着利用长读段发现SV的进展,已经引入了能够利用这些SV的基因型。基因分型是根据测序证据确定样本中某个等位基因是否存在的过程。这与变异发现是分开的,变异发现的主要目的是解决替代等位基因的结构。这种分离在二倍体生物的杂合子SV中得到了最好的说明:在发现交替等位基因后,基因型的任务是报告样本中同时存在参考等位基因和

交替等位基因。因此,基因型在很大程度上依赖于发现工具,并且必须对所报告的等位基因结构和支持所述等位基因的测序证据(例如,断点移位)之间的偏差具有鲁棒性。

最先进的基因分型采用各种算法方法,包括直接从图谱reads中对SV进行简单评估⁵,分析变异和读取k_{mer}⁶,以及基于图的重新排列方法^{10,11}。这些方法的一个共同点是,它们主要是在单个样本上进行基准测试。最常用的SV基准是用于HG00212的GIAB v0.6基准¹²。该基准是作为短读和嘈杂的长读发现变体的整合而构建的,其中定义了第1层区域,以排除分段重复和复杂的SVs。然而,其他使用较新的长读段或全基因组组装的SV研究表明,SV的数量和复杂性大于GIAB v0.6第1层区域中的亚群13。此外,通过增加含有多个相邻和/或重叠SV等位基因的位点的发生率,在群体中对SV进行基因分型增加了评估的复杂性。先前的基因型根据邻近SVs¹⁴的存在对基准测试结果进行了一些分层,但这仅是¹⁵单样本或三联样本的背景下。随着更多的样本被考虑,任何给定位点上的等位基因多样性,特别是串联重复位点的等位基因多样性预计会增加6,15。

¹Baylor College of Medicine Human Genome Sequencing Center, Houston, TX, USA. ²Broad Institute of MIT and Harvard, Cambridge, MA, USA. ³Department of Molecular and Human Genetics, Baylor College of Medicine, Houston, TX, USA. ⁴Department of Computer Science, Rice University, Houston, TX, USA.

 e-mail: Adam.English@bcm.edu




图1 | kanpig算法概述。a kanpig算法的主要步骤示意图。b GIAB v1.1 SVs中500 bp内 ≥ 50 bp插入对的序列相似性与堪培拉相似性。

在这项工作中，我们描述了kanpig，我们的长读SV基因分型软件。我们通过一个全面的基准测试框架来展示kanpig，使用一组不同的单倍型解析的长读组装来评估其准确性。我们比较了kanpig与其他长读SV基因型的基因型准确性。除了使用高置信度、单样本SVs评估kanpig之外，我们还对常用的SV调用者sniffles和多样本SV vcf发现的SVs进行基准测试。在所有实验中，kanpig始终产生更准确的基因型，并成功避免了其他基因型中常见的错误，特别是样本内和样本间相邻SVs的错误。

结果

Kanpig算法

kanpig (K-mer ANALYSIS of Pileups for Genotyping)算法包含四个主要步骤(图1a)。首先，对包含SVs的VCF进行解析，将SVs之间的距离确定为“邻域”；其次，kanpig从SVs的一个邻域构造一个变异图，其中节点持有SVs，有向边连接下游不重叠的SVs。接下来，解析一个BAM文件，查找跨越SVs邻域的长读比对，并在用户定义的大小边界(默认为50 bp至10 kbp)内生成堆积，然后对读取进行聚类，以识别最多两个单倍型。最后，执行连接变体图的源节点和汇聚节点的宽度优先搜索，以找到相对于应用的单倍型最大化评分函数的路径。

kanpig方法的一个新颖之处在于它将变体图的节点或读取的堆中的序列表示为k-mer向量，使用一个小的k值，默认为4个碱基对(bp)。k-mer向量包含所有可能的k-mer的计数($k = 4$ 为256)，并跟踪每个k-mer在序列中被观察的频率。然后将这些向量作为评分函数的一部分，通过堪培拉距离测量序列相似性¹⁶。为了计算这种相似性，kanpig使用覆盖最广的单倍型的变体集，并包括在读取的堆和路径节点的SV序列中出现最少次数(默认为2次)的k-mers。这种过滤有助于减少伪影的影响，比如测序错误。为了评估该方法的实用性，我们将k-mer向量的堪培拉相似性(1减去距离)与使用edlib¹⁷测量的序列相似性进行了比较，这些相似性来自GIAB v1.1 SVs¹⁸，超过141,680对 ≥ 50 bp且彼此之间不超过500 bp的插入SV对。k-mer向量的堪培拉相似性与传统序列相似度(图1b)的Pearson相关系数为0.994 ($p < 0.01$)，均方根误差为0.026。在这些邻近的插入对中，有41152对(29

%)的大小和edlib序列相似性超过95%，其中包括30641对发生在完全相同位置的复合杂合对。在这些相似度 $\geq 95\%$ 的插入对中，37918对(92%)的堪培拉相似度也在95%以上。因此，许多相邻的SVs高度相似，堪培拉相似度度量可以准确地度量它们。

kanpig算法的两个关键组成部分是如何在将其应用于变异图之前将读取聚类成单倍型，以及变异图如何缺少连接重叠SVs的边。通过k-mer向量对reads进行K-means聚类，最多可产生两个单倍型。然后，每个单倍型只需要在图中搜索最优路径，同时将其所有组成读取应用于相同的SVs。此外，通过不允许通过重叠变体的路径，kanpig可以防止单倍型产生冲突的基因型。例如，在图1a所示的SV的邻域中，kanpig的图确保了如果单倍型支持红色SV，它也不能支持重叠的绿色或蓝色SV。相反，如果单独评估reads或SVs，则来自相同单倍型的reads可能支持不同的、冲突的SVs，或者重叠的SVs可能冗余地从相同的read中获得支持。这可能会引起诸如两个重叠的SVs被基因分型为纯合子的问题。由于人类常染色体染色体是二倍体，因此在单个样本中与另一个现有变体重叠的纯合子变体是相互冲突的，因为从生物学上讲，同时丢失两个副本并同时丢失重叠缺失的额外副本是不可能的。Kanpig的设计通过正确处理重叠和附近的SV邻域来防止这种类型的基因分型错误。

建立结构变异基因型的基线

瓶子基因组联盟(GIAB)发布了两组结构变异，研究人员用它们来评估SV发现和基因分型工具的性能。第一个是GIAB v0.6¹²，由多个SV发现工具的结果合并构建而成；第二个是GIAB v1.118草案，来自一个高度抛光的二倍体端到端粒组装。这两个大于50 bp的插入和缺失的基准具有截然不同的完整性水平。GIAB v0.6包含9646个SVs，而v1.1包含27,560个SVs。在GIAB v0.6中，杂合与纯合变异的比率(het/hm比率)为1.16，而在v1.1中为4.15。这些基准的差异在重叠和紧密相邻的SVs环境中尤为显著。GIAB v0.6中没有与其他SV相距1kbp的一级通过SV，而GIAB v1.1中有15685台(43%)SV至少有一个邻居。这些对热/热比和相邻SVs的观察结果并不是独立的，因为有至少一个邻居的GIAB v1.1草案SVs中有92.2%是杂合的，而杂合率为65.5%




图2 | 47个样本中基因型在单样本组装衍生SVs上的表现。左侧:三个读取覆盖的基因型一致性a b由SV型缺失(DEL)和插入(INS)分层c由SV位置在串联重复序列内或外分层。请注意,为了可读性,左图截断了y轴(50-90%)。d基因型一致性

1000个碱基对内的相邻SVs(上)和SVs占相邻数量的比例(下)。e基线组合变异中每个样本的平均基因型分布以及每种工具的结果。REF = 参考纯合子, HET杂合子, HOM纯合子交替, NON缺失基因型(./.)。所有条形图误差条代表均值的95%置信区间。

无邻点杂合(卡方检验 $p < 0.01$)。因此,主要以GIAB v0.6为基准的SV基因型可能偏向于纯合子SV的一个子集。由于这些原因,在kanpig的开发中,我们利用GIAB v1.1草案和HG002的内部测序重复进行培训。

为了全面测试kanpig,我们利用来自人类泛基因组参考联盟(HPRC)¹⁹的高置信度片段,使用dipcall v0.320²⁰ GRCh38从47个遗传多样化的基因组片段中创建SVs(见“方法”部分的“数据收集”小节)。为了确保装配衍生的SVs具有高质量,我们使用truvari6将HPRC HG002 SVs与GIAB v1.1 SVs进行了比较。结果显示,精密率为0.996,召回率为0.987,基因型一致性为99.3%。从HPRC组装和浸管管道到GIAB v1.1的HG002变体的一致性表明,该管道足以在所有HPRC样品中生成基线vcf进行测试。

单样本SV基因型

为了评估kanpig的性能,我们收集了来自相同的47个HPRC个体的32倍覆盖的PacBio HiFi长读,这些长读包括上述装配衍生的基线变体(参见“方法”部分的“数据收集”小节)。我们使用kanpig和其他三种长读SV基因型对每个样本的常染色体SV进行了5

0 bp至10kbp的基因型分型:SVJedi-graph¹⁴(以前称为SVJedi);Sniffles2²¹(以下简称sniffles);cuteSV²²。请注意,sniffles和cuteSV是长读SV发现工具,仅具有基因型(也称为“强制调用”或“-fc”)模式,这里进行了测试。

kanpig预测基因型的平均一致性为82.1%,而SVJedi为74.2%,sniffles-fc为67.1%,cuteSV-fc为63.8%。基因型表现的测量在读取的两次下采样中重复到16倍和8倍覆盖率(图2a)。观察到,较低的覆盖率导致较低的基因型一致性。值得注意的是,kanpig在8倍(77.8%)的表现高于其他工具在32倍的表现。补充数据1中提供了按覆盖率、SV类型和与TRs重叠程度划分的样本中工具平均基因型一致性的完整表。

每个样本平均产生9706个缺失和16870个插入。按SV型对基因型表现进行分层发现,所有工具的缺失基因型都比插入基因型具有更高的一致性(图2b)。在缺失上表现最好的基因型是SVJedi,平均基因型一致性为88.2%,其次是kanpig,平均基因型一致性为86.5%。对于插入,kanpig的基因型一致性为79.5%,远高于SVJedi的66.1%。Kanpig在不同SV类型间的表现不平衡(即差异)最小

删除和插入一致性之间的不平衡为7.0个百分点(p.p)，而其他工具的不平衡为20.5到23.2个百分点。

SVs的另一个重要分层是它们与串联重复序列的重叠，因为它们包含约70%的SVs，并且由于其序列背景而构成独特的挑战¹⁵。我们发现kanpig在TRs内和TRs外的SVs基因型一致性分别为81.7%和89.0%(图2c)。SVJedi的性能第二高，在TRs内部为72.4%，在外部为78.6%。

基因型正确分配基因型的能力的一个强有力的预测因子是邻近变异的存在，因为它们增加了被评估位点的复杂性。我们对工具的基因型一致性进行了测量，并按1000 bp内有邻居和没有邻居(即分离)的变异进行分层(图2d)。在50.8%的分离SVs样本中，基因型一致性在95.0% (SVJedi)和92.7% (kanpig)之间。在其余49.2%的SVs样本中，kanpig的平均基因型一致性最高，为70.9%，其次是SVJedi，为52.5%，而sniffles-fc和cuteSV-fc低于40%。这表明所有被测试的基因型在分离的SVs上表现相当好，而kanpig对彼此接近的SVs正确基因型的能力使其不同。

正如上面描述的GIAB v1.1 SVs中所观察到的，在一个个体中，杂合子SVs的数量大约是纯合子SVs的四倍，并且杂合子SVs比纯合子SVs更频繁地与另一个SV相邻。接下来，我们探索了组装衍生SVs中基因型的分布，以证实这一观察结果，并评估每种工具对杂合和纯合SVs进行分类的能力(图2e)。我们发现kanpig每个样本的平均热量/热量比为3.00，最接近组装SVs的平均热量/热量比为4.58。其他工具更倾向于将热/热比在1.38至1.10之间的纯合子基因型分配。由于本实验中评估的每个变异都是根据其各自的组合而未知存在的，因此任何参考纯合状态的基因型的分配都是错误的。Kanpig的平均参考纯合子错误率第二高，为11.4%，仅次于cuteSV-fc的16.5%。然而，上述基因型一致性测量已经因这些错误而受到惩罚，并没有阻止kanpig记录最高的基因型一致性。最后，最高的缺失率(即没有足够的证据来分配任何基因型:./)来自kanpig，每个样本平均有3.5%的变异，而SVJedi次之，为1.2%。

这些基因型一致性、het/home比、参考纯合误差和缺失率的测量表明，在某些分层中，其他工具可能能够比kanpig更好地确认替代等位基因的存在(即召回率)。然而，kanpig在所有分层中始终如一的高正确基因型分配(即精度)导致总体基因分型准确性显著提高。

单样本发现基因分型

大多数生成SVs的项目将无法访问高质量的程序集，而是使用sniffles等工具从原始读取的对齐中发现SVs。SV发现工具容易出现不完善的变异表示、假阴性和假阳性等错误，这些错误都对SV基因型的后续使用提出了挑战。为了测试kanpig处理变异图中的错误的能力，我们使用sniffles发现在47个HPRC 32x样本上生成SV，使用测试工具进行基因分型，并将结果与装配衍生的SV集进行比较。

在32×覆盖实验中，kanpig的基因型平均一致性为85.0%，而SVJedi和cuteSV-fc的基因型一致性分别为76.2%和78.1%。由于SVs是用鼻塞发现的，我们分别测量了其原始发现基因型和强制基因型模式的一致性，分别为80.5%和80.4%。总的来说，在分析嗅嗅发现VCF时，基因型的覆盖率、SV类型和TR状态的相

对表现模式与分析上述装配衍生的VCF时相同(补充数据2)。

除了基因型一致性外，我们还测量了基因型如何改变现有(杂合或纯合交替)发现变异的精度和召回率。一个完美的基因型会将所有假阳性(FP)称为参考纯合子，从而“去除”FP，同时保留所有真阳性(TP)的当前状态。不出所料，擤鼻涕力基因分型对擤鼻涕发现的影响最小，每个样本只有23个FPs和87个TP基因分型作为参考纯合子。Kanpig平均去除52个FP变异和206个TP变异，而cuteSV-fc平均去除51个FP变异和745个TP变异。有趣的是，虽然SVJedi在每个样本中平均只丢失了50个TP变体，但它也在每个样本中发现了63个额外的FP变体。这些额外的假阳性是由发现的变异引起的，这些变异最初的质量很差，并且是参考纯合基因型，但SVJedi确定了该变异的存在，因此产生了额外的present FP。补充数据3包含工具对47个样本的平均精度和召回率以及32倍、16倍和8倍的三种读取覆盖率的影响的完整报告。

多样本SV基因分型

对跨多个样本的SV进行基因型分析的输入是包含每个样本SV发现结果的VCF，这些结果已被整合以去除样本之间冗余的SV。为了测试kanpig处理多样本VCF的能力，我们合并了上述47个HPRC样本上的sniffles发现变体，并使用^{truvaric}折叠相同类型的假定冗余变体表示，在500 bp内，序列和大小相似≥95%(方法:数据收集)。最初发现的SV总共有561,735个变异，而truvari崩溃留下了257,323个变异(减少54.1%)作为基因型的输入。

Kanpig与基线SVs的基因型一致性最高，为84.9%，其次是SVJedi为55.4%，cuteSV-fc为34.1%，sniffles-fc为33.8%。此外，程序目前的SV f1分数(精度和召回率的调和平均值)为kanpig 0.948，SVJedi 0.817，cuteSV-fc 0.611，sniffles-fc 0.605。关于多样本SV基因型表现的详细信息可参见补充数据4。

虽然kanpig的多样本性能与其单样本SV基准一致，但其他工具在基因分型一致性方面显著降低。为了确保SV发现和SV合并的过程不是这些性能变化的混淆因素，我们采用每个样本的程序集派生的SV，并使用bcftools合并²⁵对它们进行合并。因此，这个多样本VCF包含了一整套未经操纵的高置信度SV。由于在基因分型之前没有合并SV，VCF包含许多高度相似的SV，这些sv在其衍生组装的上下文中是完全有效的表示，但在多个样本的上下文中表面上是冗余的表示²⁴。来自47份HPRC样本的整合组装衍生SV包含403,031个常染色体SV，分布在50 bp至10kbp之间。共有371,771个SV(92.2%)与另一个SV在1000 bp以内;其中346,843例(86.0%)与另一个相同类型的SV在500 bp内，在大小和序列上也至少95%相似。

Kanpig的多样本SVs基因型一致性最高，平均为86.6%，其次是SVJedi，平均为42.8%(表1)。CuteSV-fc和sniffles-fc的平均基因型一致性更低，分别为12.7%和12.2%。kanpig基因型样本当前SV(非参考纯合子)的平均精度为0.973(平均598 FPs)，而SVJedi基因型样本的精度为0.564 (19,515 FPs)。cuteSV-fc和sniffles-fc平均每个样本超过100,000 FP SV，其精度降至0.20以下。同时，kanpig保持了0.953的合理召回率，低于其他基因型，

表1 | 多样本SV基因分型性能

Program	GT Concordance	TP-base	TP-comp	FP	FN	Precision	Recall	f1
kanpig	86.6%	22,671	21,640	598	1129	0.973	0.953	0.963
SVJedi	42.8%	25,153	25,317	19,515	327	0.564	0.987	0.718
cuteSV-fc	12.8%	22,928	22,981	104,495	1,051	0.180	0.956	0.303
sniffles-fc	12.3%	24,886	24,986	121,394	763	0.171	0.970	0.290

当给定装配衍生SVs的多样本VCF和32倍长读覆盖率时，47个样本的基因型的平均性能。SV匹配使用特鲁瓦里台架进行，详细内容见测量基因分型性能的方法。




图3 | 多样本SV基因分型性能。发现的SVs (a)和来自47个样本的装配衍生SVs (c)的邻居数的基因型一致性，上图表示每个邻居数的基因型一致性，下图表示项目级VCF中具有指定数量计数的SVs的百分比。发现的(b)和装配衍生SVs的基因型分布(d)。对于b, d, x轴被截断到20-100%

达到了至少0.956的召回率。这些观察结果表明，kanpig能够在多样本SV基因分型中保持高的基因分型一致性，因为它具有很高的精度，而其他基因型错误地将reads应用于样本中不存在的替代等位基因。关于组装衍生的多样本SV基因型表现的详细信息，包括覆盖度、SV类型和与TRs的重叠，请参见补充数据5。

对于流鼻涕发现/特鲁瓦里合并SVs和装配衍生SVs，基因分型一致性的最强预测因子是在一个位点的可能SVs集中存在邻近的SVs(图3)。在1000 bp内无邻

居的SVs在已发现的SVs上的基因型一致性为87.9% (kanpig)和75.6% (SVJedi)，在装配衍生的SVs上的基因型一致性为97.5% (kanpig)和82.0% (SVJedi)。这些分离的SVs仅占已发现SVs的16.5%，占组合衍生SVs的7.8%。对于其余至少有一个邻居的SVs，kanpig对发现源性SVs的基因型一致性为83.2%，对装配源性SVs的基因型一致性为83.8%。其他工具在与邻居的多样本SVs上的基因型一致性低于47.2%。

对kanpig结果的分析没有发现重叠的纯合子SVs基因型冲突的证据

表2 | 计算性能

	Single-Sample VCF		Multi-Sample VCF	
	Chromosome 1	Whole genome	Chromosome 1	Whole genome
kanpig	18 s/0.02 Gb	43 s/1.7 Gb	1 m 6 s/0.41 Gb	2 m 10 s/3.42 Gb
SVJedi	7 s/0.2 Gb	1 m 35 s/1.1 Gb	–	4 m 4 s/9.61 Gb
sniffles-fc	1 m 10 s/0.2 Gb	56 s/1.3 Gb	1 m 11 s/0.44 Gb	1 m 32 s/16.25 Gb
cuteSV-fc	32 s/0.8 Gb	1 m 3 s/1.2 Gb	35 s/0.89 Gb	4 m 56 s/9.1 Gb

在测试数据上运行5次时，每个单元以Gb (Gb)为单位保存平均运行时/最大内存使用量。运行时的单位是(h)分钟，(m)分钟和(s)秒。多样本VCF中含有47个样本的SVs。对1号染色体进行1核检测。全基因组测试给出16个核。SVJedi仅在数据上运行一次测试，因为它封装了对minigraph的调用以生成对齐，而其他工具使用预生成的bam。多样本1号染色体实验的Minigraph在运行12小时后终止，因此被排除在外。

纯合子SVs。然而，在多样本发现的SVs中，至少有一个样本的SVJedi基因型冲突占29.4%，cuteSV-fc占40.7%，sniffles-fc占45.7%。对于多样本组合衍生的SVs，具有冲突基因型的≥1个样本的变异百分比在kanpig中为零，在SVJedi中为40.5%，在cuteSV-fc中为59.1%，在sniffles-fc中为66.5%。来自其他基因型的大多数错误不是来自杂合子或纯合子状态之间的错误分配，而是无法将参考纯合子状态分配给样本中不存在的变体。为了进一步说明这些基因型错误产生的原因，我们研究了每个样本的平均基因型状态分布(图3c/d)。在合并的程序集派生的VCF中，跨样本发现了403,031个SVs。对于任何一个样本，这些SVs的平均7%(~ 28000)预计存在(杂合子或纯合子交替)。Kanpig基因分型平均7%的SVs存在，6%缺失。SVJedi将15%的SVs基因分型为存在，16%为缺失，而sniffles-fc和cuteSV-fc分别将33%和66%的SVs基因分型为每个样本存在，两者的缺失率均低于1%。

纳米孔R9/R10测序性能

以上实验均在PacBio HiFi测序上进行，据报道读取精度为~99%²⁵。另一种可用的长读测序技术是牛津纳米孔技术公司(ONT)，该公司最近发布了一项更新，将测序化学准确度从~96% (R9化学)提高到~99% (R10化学)²⁶。为了研究kanpig利用ONT读取的能力以及读取准确性对基因分型的影响，我们运行了3个全基因组样本，这些样本具有公开可用的R9和R10重复，覆盖范围为30倍²⁷。我们发现，当对单样本汇编SV进行基因分型时，kanpig在R9 reads上的平均基因分型一致性为77.8%，在R10上的平均基因分型一致性为80.1%(补充数据6)。ONT和PacBio reads基因分型性能的可比性表明，所有工具都可以有效地利用这两种技术。然而，与R10相比，使用R9的kanpig一致性下降了2.3个百分点(p.p)，高于其他工具(第二次嗅探-fc为1.5p.p)，这表明kanpig更依赖于碱基对水平的读取准确性。

ONT样本是HPRC PacBio样本中三个相同个体的技术复制。因此，我们还检查了基因型在重复中一致地将基因型应用于样品组装衍生的SV的能力。最一致的基因型是SVJedi，72.2%的SVs在所有三个重复上都分配了正确的基因型。kanpig次之，为62.2%。仅考虑读取精度较高的两种技术(PacBio HiFi和ONT R10)时，72.7%的SVJedi基因型和71.4%的kanpig基因型是一致和一致的(补充数据7)。

计算性能

Kanpig是用Rust编写的，目的是实现高速和内存安全，并在开源MIT许可下提供。Kanpi

g可以从源代码构建，也可以使用适用于posix兼容系统的可用静态链接二进制文件运行。为了测试kanpig相对于其他基因型的速度和内存使用情况，我们首先测试了每个工具在从单个32x样本中发现的1号染色体sniffles调用上的计算性能，仅使用单个核心和限于1号染色体的12x readset。在对BAM文件进行操作的工具中，kanpig是最快且内存消耗最少的(表2)。为了运行minigraph²⁸，SVJedi的进程需要FASTQ格式的未对齐读取作为输入。因此，为了进行比较，我们从SVJedi的运行时间(4.6小时)中减去minigraph的运行时间。所有测试的基因型都可以使用多线程运行，因此在给定16个内核、全基因组32x嗅探发现调用和单个20x样本时也进行了测试。同样，kanpig是最快的。我们在47个样本的sniffles VCF上重复了1号染色体和全基因组测试，发现kanpig是第二快、内存消耗最少的工具。

讨论

在这里，我们提出了详细的描述和评估我们的长读SV基因分型工具kanpig。通过利用来自多个样本的高质量SV基准和在各种条件下的测试，我们显示kanpig比其他基因型具有更高的准确性。我们的研究表明，kanpig在大多数分层和用例中始终优于其他长读SV基因型。具体来说，我们发现kanpig更频繁地将正确的基因型分配给主导SV景观的附近(即邻近)SV，特别是在分析跨多个样本的SV时。

理想的SV基因分型方法不应该只是试图最大化样品中存在的SV的数量。这种行为对于单样本SV基因分型可能是成功的，但是，正如本研究证明的，在处理SV群体集时，将导致大量假阳性和冲突的基因型等问题。许多SV基因型的一个主要缺陷是无法处理相邻的SV，这种情况发生在高度相似但仍然不同的SV彼此接近时。邻近的SVs主要存在于串联重复序列中，这些重复序列具有高度多态性，约占人类基因组中所有SVs的70%。如果对相邻SV的评估不当，可能会产生在每个样本中产生生物学上不可信的单倍型的基因型(例如，在二倍体基因组中有三个重叠缺失)，从而破坏下游分析。Kanpig能够正确地对邻近的SV进行基因分型，因为它的算法是评估在基因组窗口上构建的变异图，而不是独立地搜索支持每个SV的已读证据。此外，kanpig通过变体图测量长读和路径之间的序列相似性，有助于确保在多个SVs中选择单个、得分最高的最优路径。

其他SV基因型的局限性被忽视的部分原因是由于选择基线SV作为工具的基准。GIAB v0.6 SV基准在推进SV发现算法方面发挥了重要作用。然而，当代对SV流行率和组成的理解强调需要更复杂的基准，如GIAB v1.1 SV和

HPRC^{组件}正如我们所示, GIAB v1.1基准草案的SV比其前身多了约2.5倍, 其中包括约43%的SV在1000 bp内, 以及约4的热/热比。此外, HPRC组合(由47个遗传多样性个体组成)在每个样本50bp-10kbp和4 het/hm比率之间支持约2.6万个SVs的变异计数。kanpig不仅能够在这高置信度基准上实现最佳的基因分型一致性, 而且我们还证明了kanpig能够准确地从流鼻涕中发现SV的基因分型。虽然本文主要报告了使用dipcall和sniffles发现VCF的测试结果, 但kanpig能够使用具有准确断点和完整等位基因序列(即非符号等位基因)的SV处理任何兼容的VCF, 这些序列通常由许多长读SV发现工具产生。

当给定PacBio HiFi和ONT R9和R10读取时, 我们对kanpig的准确性进行了基准测试, 以展示其在多种长读技术中的实用性。然而, SV基因型不仅依赖于测序技术, 而且还依赖于所提供的输入SV描述的质量, 因为基因型的设计是为了调查假设的SV。有趣的是, kanpig在对SVs变异图进行测序时的精度能够减少错误发现的SVs数量, 同时保持较高的召回率, 从而不仅提高了呼叫的基因型, 而且提高了每个样本报告的SVs集。这取决于SV调用者提供的准确和完整的等位基因描述信息。

除了测序技术和SV发现工具外, 多样本项目(如系谱或群体)的SV基因分型也取决于所采用的SV合并策略。我们之前概述了不准确的SV合并的原因和后果, 并在^{muvariant}中实现了我们的发现。SV合并的替代方法可以用来创建kanpig的输入(例如^{jasmine29})。更一般地说, 研究人员需要意识到, 过度合并或合并不足不仅会影响SV基因分型方法的性能, 还会影响所有后续分析的性能。未来的工作需要确切地了解DNA测序技术, SV发现工具和SV合并方法的组合最有效地报告SV, 而这里提出的工作只是解决该领域对准确SV基因型的需求的一个开始, 这是管道的一个步骤。

任何旨在协助基因组学研究人员生物信息学工具都必须经历持续的开发和维护。虽然这里展示的kanpig版本可以立即开始为研究人员服务, 但进一步的改进是可能的。例如, 优化的BAM/CRAM访问模式可以减少运行时间, kanpig的设计应该能够利用单plotagged读取来辅助读取聚类以及注释远程相位信息。目前, kanpig仅限于解析连续对齐, 并且不利用通常发生在较大SV周围的分裂或剪切对齐信号。因此, kanpig目前适用于小于读取长度的变体。未来版本的kanpig应该能够结合分裂/剪切比对, 以获得大于~10 kbp的更好的SV基因型。此外, kanpig目前需要长读比对来跨越每个基因座变异图中变异的邻域。然而, 未来的kanpig实现可能会通过对相应的子图应用部分比对来潜在地放宽这一要求, 从而提高kanpig的灵敏度, 特别是在低覆盖率的情况下。虽然这需要仔细设计, 以确保在对邻近SV进行基因分型时, kanpig的准确性不会出现回归。

总之, 我们描述了一种新的SV基因型kanpig, 以及改进的SV基因型对SV研究的潜在影响。本文在高可信度基准和其他数据集上提出的结果应促进kanpig在大规模SV研究中的快速采用, 从而提高群体SV结果的可靠性, 并可能为生物学和临床研究中的新发现做出贡献。

方法

Kanpig算法

K-mer向量。变异序列被编码为k-mer向量。设n为核苷酸n = {A, G, C, T}的集合, 函数E为n中每个元素的两位编码, 使得A = 0; G = 1; C = 2; T = 3。设S为长度为l的核苷酸串, 使得S = n₀, n₁, n₂, ..., n_{l-1}。大小为K的K-mer K是S的子串, 从基于0的位置i开始, 定义为K_{ki}(S) = n_i, n_{i+1}, ..., n_{i+K-1}。K-mer向量(V)保存了一串核苷酸中所有K-mer的数量。n的每个可能的k-mer组合都可以映射到大小为|n|^K的概念数组V的唯一索引j, K_{k0}的索引j可以使用左位移操作(<<)和公式计算:

$$j = \sum_{i=[0..k)} [E(S_i) \ll ((k-i-1) \cdot 2)] \quad (1)$$

例如, 序列“CAGT”的前3-mer的j为:

$$(2 \ll (2 \cdot 2)) + (0 \ll (1 \cdot 2)) + (1 \ll (0 \cdot 2)) = \text{binary}100001 = 33$$

然后增加V_j。接下来, 对于Sk的每一个n ..L-1, 我们改变j via

$$j = ((m \& j) \ll 2) + E(S_i) \quad (2)$$

这个操作通过首先屏蔽(m)最左边的两个位, 左移剩下的位两次, 并在再次增加V_j之前添加当前核苷酸的编码来更新j。对于示例序列“CAGT”, 第二个3-mer的j是7(二进制000111)。小于k的序列不能被矢量化, 因此返回一个全为零的向量。

变量比较。两个长度为n的k-mer向量(p & q)的相似性可以使用堪培拉距离函数和绝对值函数abs来计算

$$SZ(p, q) = 1 - \sum_{i=[0..n)} \text{abs}(p_i - q_i) / (\text{abs}(p_i) + \text{abs}(q_i)) \quad (3)$$

为了限制小排序错误的影响, 不常见的k-mer (abs(pi) + abs(qi) < minkfreq)从(3)中被排除。kanpig默认将minkfreq设置为2, 但这个阈值可以由用户通过参数设置。默认k-mer大小为4 bp, 这是从测序实验对GIAB草案v1.1 SVs的性能的实证测试中选择的。k-mer大小及其与edlib序列相似度的有限影响见补充数据7。

除了比较变异的k-mer向量序列相似度外, 还可以比较两个变异序列(a,b)的大小相似度。删除构成了序列的移除, 因此长度为负, 而插入则增加了序列, 长度为正。要比较两个向量的相关长度必须具有相同的符号(例如, 两个删除都具有负大小), 并且它们的大小相似度计算为

$$SS(a, b) = \min(\text{length}(a), \text{length}(b)) / \max(\text{length}(a), \text{length}(b)) \quad (4)$$

认为两个向量相等所需的最小大小和序列相似性阈值默认为0.90, 可以由用户通过参数设置。

这种k-mer向量和比较指标的设置允许对一个区域内的多个变量进行求和, 以便在该区域上产生“netchange”。例如, 两个100 bp的缺失与一个198 bp的缺失具有99%的大小相似性。同样, k-mer向量可以求和以包含多个变体的总k-mer计数。

变体图的构建

包含完整等位基因(REF和ALT序列)的变体调用格式文件(VCF)被解析并划分为变量块

在-chunksize的距离内。这就产生了一组变异，其中上游最多的变异的起始位置和下游最多的变异的结束位置之间的距离与同一染色体上的任何其他变异之间的距离至少为-块大小的碱基对。构建一个有向图，其中节点表示每个变体，边缘将变体连接到所有不重叠的下游变体。在将变异转化为节点的过程中，锚碱基被修剪，剩余的参考和替代序列被存储为V(ALT)-V(REF)的k-mer向量。此外，变体所描述的变化长度记录为长度(ALT)-长度(REF)。所有变体的上游源节点被添加到具有所有变体的边的图中，以及具有来自所有变体的边的下游汇聚节点。请注意，只有变体是k-mer矢量化，而不是它们之间的参考序列(即不变基)。

堆积生成。对于每个独立的变体图，从跨越图区域的BAM文件中读取对齐的CIGAR字符串被解析以识别插入和删除变体，并跟踪哪些读取支持每个变体。默认情况下，只有完全跨越区域并具有最低映射质量(- minmapq 5)以上的主对齐被包含在堆积中，并且在参数化的大小范围(- sizemin 50 -sizemax 10000)内的插入和删除变体被分析。每个变体的序列被转换成一个k-mer向量，并记录大小。具有相同堆变体集的Reads与记录的组成Reads计数合并，从而创建假定的单倍型。

单倍型聚类。我们将单倍型定义为通过基因组窗口上的对齐读来描述的一组变体。单倍型包含一组变体的k-mer向量和变体相对于参考的变化大小。在上面描述的堆积生成过程中产生的假定单倍型集使用k-means聚类(使用k = 2)对其变体的k-mer向量的总和进行分组，以识别最多两个备用等位基因单倍型。对于每个产生的聚类，选择读取次数最多的假设单倍型作为该单倍型的代表。如果只鉴定出一个交替单倍型，则分析交替和参考纯合读覆盖率的比例(参见方法:基因分型和注释)，以确定该位点是纯合交替还是杂合。如果鉴定出两个聚类，kanpig允许大于大小相似阈值(—hapsim默认值:1)的单倍型被整合，并且认为该位点具有单个交替等位基因。注意，这个阈值在默认情况下是关闭的，因此不进行整合。否则，这两个交替的单倍型被认为是一对复合杂合等位基因，并返回应用于变异图。

将单倍型应用于变异图。给定一个基因座的单倍型和变异图，kanpig通过最大化(5)中描述的分数的，在变异图中搜索与单倍型变异最匹配的最优路径。该算法从源节点开始进行宽度优先搜索，并探索外向边以构建通往相邻节点的路径。这些部分路径被添加到一个二元最小堆中，该最小堆根据路径的长度对路径进行优先级排序，具有与单倍型长度更相似的总节点“变体”长度的路径获得更高的优先级。

在每一步中，kanpig都会从堆中弹出优先级最高的路径，识别其尾部节点，并通过访问该节点的所有外向边来扩展路径。新扩展的部分路径被推回到堆上。当一条路径到达汇聚节点时，在应用评分函数之前，通过将单倍型的k-mer向量和单倍型变体的大小相加，并分别对路径的节点进行评分。只有满足用户指定的大小和序列与单倍型相似性最小阈值的路径才会被

评分。为了减少计算开销，特别是对于具有许多节点的图，kanpig引入了一个用户定义的参数(—maxpaths, 默认值:5000)来限制比较路径的数量。当所有可能的路径都被评估完，或者被检查的路径数量达到—maxpaths时，搜索就会终止。

分裂变体表示可能发生在以下情况:例如，单倍型包含100-bp的缺失，而图中有一条带有单个100-bp缺失的路径，也有一条带有两个50-bp缺失的路径，所有这些都描述了相同的变化。为了处理分裂变异，kanpig会对单倍型的变异计数和路径的节点计数之间的差异进行惩罚，从而优先选择与从对齐读取中观察到的变异表示更一致的路径。

为了解释变异图中潜在的假阴性(即单倍型包含输入VCF中不存在的变异)，kanpig允许在k-mer向量和变异大小求和期间跳过单倍型中的变异，并对分数进行惩罚。只有当单倍型的大小或序列相似性低于最小阈值时，才会发生跳过。跳跃性会将单倍型的总大小和k-mer向量暂时替换为每个n-1个变体子集的大小和k-mer向量。跳过程会一直持续，直到部分单倍型满足最小大小和序列相似性阈值，或者直到测试了最多n-3个变体(即最多3个跳过的变体)。

$$\text{Score}(P, H) = ((SS(P, H) + SZ(P, H)) / 2) - (\lambda_g \cdot |L(P) - L(H)|) - (\lambda_f \cdot N) \quad (5)$$

路径和单倍型的kanpig评分函数见(5)，其中P和H分别是路径和单倍型，SS是(3)中定义的序列相似性，SZ是(4)中定义的大小相似性。L函数测量路径中的节点数或组成单倍型的变体数。变量N是单倍型中假阴性(即跳过)变异的数量。分裂变异表示的惩罚 λ_g 默认为0.01，而假阴性表示的惩罚 λ_f 默认为0.10，两者都可以使用用户定义的参数设置。

基因分型和注释。对于每个位点，上述过程收集了支持单倍型的reads计数以及该单倍型支持的最高得分路径(即VCF变体)的节点集。不支持单倍型的读取数(要么支持第二个备选等位基因单倍型，要么支持参考等位基因)也被收集。Knpig接下来评估每个VCF变体，如果其对应的节点处于单倍型的最佳路径上，则认为该变体存在于该单倍型中。接下来，kanpig分析支持变体存在(得分最高的路径上的变体)和不存在(不在路径上的变体)的reads的比率，并使用与Chian等人相同的贝叶斯公式确定变体的二倍体基因型⁸。该公式利用了参考纯合、杂合和纯合交替读比的三种等位基因覆盖率先验。Knpig对覆盖率小于10倍的基因座设置这些先验为1e-3、0.55和0.95，对覆盖率至少为10倍的基因座设置为1e-3、0.50和0.90。然后计算给定先验的每个基因型状态的条件概率，并分配最可能的状态。然后利用这些衍生的可能性来计算基因型质量分数(对分配的基因型状态的置信度)和样本质量分数(在任何基因型状态下存在备用等位基因的置信度)。基因型质量得分推导为-10乘以第二可能基因型状态和最可能基因型状态的绝对差值。样本质量得分推导为-10乘以参考纯合子似然的绝对差和杂合子和纯合子交替似然的log10和。基因型和样本质量得分的范围从0(最低质量)到100(最高质量)的人工上限。

除了基因型、基因型质量评分和样本质量评分外，kanpig还将记录每个变体的附加注释。这包括两种常见的基因分型深度注释(DP:用于评估该变异的基因座的总reads数)和等位基因深度注释(AD:来自DP的多少reads支持参考等位基因和备用等位基因)。报告了(5)中描述的为一个基因座创建的单倍型到通过变异图的最终选择路径的得分，以及一个阶段集(PS)唯一标识符，该标识符注释了组成每个独立变异图的一组变异。

最后，将过滤标志(FT)填充为具有状态的位标志，以帮助用户过滤基因型。0的标志可以认为是通过的。位被定义为:0x1 -从变体匹配路径观察到的基因型不等于通过测量支持两个等位基因的reads比例观察到的基因型;0x2 -基因型质量评分小于5;0x4 -观察覆盖率小于5;0x8 -非参考纯合变异的样本质量得分低于5分;0x16 -替代等位基因支持覆盖率低于5;0x32 -得分最高的路径没有使用整个单倍型，这可能表明相对于读到的证据，变异图中存在假阴性。请注意，kanpig的过滤标志可供用户使用，但未用于更改此处呈现的kanpig结果。

数据收集

HPRC组件和PacBio CCS读取从HPRC AnVIL工作空间下载(参见数据可用性)。只考虑assembly_sample表中的样本。本研究中用于测试的样本元数据见补充数据8。在删除每个单元格中的BAM和FASTQ文件中的重复条目后，从样列表的hifi列下载CCS读取。对于每个样本，读取被子集到所需的覆盖范围如下。给定一个源文件列表，该列表被随机排列。对于按排列顺序排列的每个文件，如果它是BAM(使用samtools FASTQ)，则将其转换为FASTQ，并将其附加到不断增长的FASTQ，直到达到或超过所需的碱基总数(使用seqkit统计数据测量)。然后随机排列FASTQ(使用terashuf <https://github.com/alexandres/terashuf>)，并保留达到所需碱基数量的前缀。ONT读取从CARD谷歌云桶下载(见数据可用性)。具体来说，我们从目录X/reads/ (R9读取)和X_R10/reads/ (R10读取)下载了每个样本X的fastq.gz文件，并按照上面的描述对这些文件进行了下采样。

给定每个高质量的汇编和GRCh38参考，使用默认参数运行dipcall v0.3，并使用bcftools norm -multiallelics -拆分多等位基因记录。最后，只有长度至少为50 bp且FILTER字段等于PASS或的INS和DEL事件。’被保留。为了评估装配衍生SVs的预期质量，使用默认参数和床文件(GIAB v1.1高置信度区域和dipcall高置信度区域的交叉点)运行truvari bench和truvari refine，将HG002装配SVs与GIAB v1.118进行比较。通过对所有单样本dipcall VCF执行bcftools合并来创建多样本dipcall VCF，然后执行最后的bcftools规范—multiallelics—以删除任何剩余的多等位基因记录。

每个覆盖的PacBio CCS读数使用pbmm2 1.13.0将pbmm2 align -预设CCS映射到GRCh38。单样本发现VCF是通过在每个样本的32倍CCS BAM上以发现模式运行Sniffles 2.3.3来创建的，使用默认参数和来自 [https://github.com/PacificBiosciences/pbsv/tree/master/](https://github.com/PacificBiosciences/pbsv/tree/master/annotations) annotations的串联重复轨道。然后按如下方法清理得到的VCF。BND和CNV记录被删除，以及象征性的INS。使用参考填充每个符号DEL和INV的ALT序列，并将每个DUP转换为位于相同

起始位置的INS。SVLEN字段与REF和ALT字段一致，并且删除了大于1mb的调用。多样本发现VCF是通过运行bcftools merge—merge none在所有清理过的单样本VCF上创建的，然后再执行以下truvari v4.2.2命令：

```
truvari collapse -- sizemin 0 -- sizemax 1000000 -- keep common -- gt all
```

使用minimap230 ^{v2.28}将ONT读取映射到GRCh38，参数为-ayYL—MD—eqx—cs，并为R9读取指定-x map-ont，为R10读取指定-x lr:hq。

长读基因型运行如下。Sniffles 2.3.3在默认参数的基因分型模式(—genotype-vcf)下运行。cuteSV 2.1.1使用以下标志运行，这些标志来自于它的命令行帮助。CCS为：

```
--max_cluster_bias_INS 1000 --diff_ratio_merging_INS 0.9
--max_cluster_bias_DEL 1000 --diff_ratio_merging_DEL 0.5
--merge_ins_threshold 500 --merge_del_threshold 500
--min_support 1
```

For ONT reads:

```
--max_cluster_bias_INS 100 --diff_ratio_merging_INS 0.3
--max_cluster_bias_DEL 100 --diff_ratio_merging_DEL 0.3
--merge_ins_threshold 500 --merge_del_threshold 500
--min_support 1
```

SVJedi-graph 1.2.1在—minsupport 1和所有其他参数设置为默认情况下运行。Knpig 0.3.1使用GRCh38倍体BED文件运行，单样本VCF参数如下：

```
<s:1> <s:3> sizemin 20 <s:2> sizemax 10000 chunksize 1000 <s:
2> <s:2>: 处罚 0:02 hapsim 0:9999<s:1> sizesim 0:90 seqsim 0:
85maxpaths 10000
```

，对于多样本vcf，参数如下：

```
--sizemin 50 --sizemax 10000 -- chunksize 500
-- gpenalty 0.04 -- hapsim 0.97
```

这些kanpig参数的选择是基于在GIAB草案v1.1 SVs上对kanpig进行的独立功能测试，以及本文中未使用的测试结果的测序实验。请注意，我们修改了SVJedigraph和cuteSV的“minsupport”参数，以确保与sniffles和kanpig进行一致的比较，后者分析至少有一个支持读取的区域。此外，在基准测试之前，没有对任何基因型的结果进行后处理-例如通过最小基因型质量进行过滤。我们在三对32倍CCS BAM和单样本发现vcf上测试了LRcaller ^{1.031}，但它在具有128GB RAM的云VM上被操作系统扼杀了，所以我们将其排除在分析之外。

测量基因分型性能

对于组合衍生变异的单样本基准实验，在比较基线和预测基因型之前，使用bcftools merge -m none合并原始VCF和基因型VCF 50 bp至10,000 bp之间的SVs。阶段信息被忽略，例如1| = 0|1。然后计算常染色体上的SVs以及起始和结束在dip报告的高置信度区域内的SVs。基因型缺失的SVs(如../)从总呼叫数中单独计算，基因型一致性计算为匹配基因型数超过总呼叫数。

对于所有其他基准测试实验,使用truvari v4.2.2和参数bench - pick ac -no-ref -sizemin 50 -sizemax 10000以及dipcall的高置信度区域将装配衍生的单样本变体与基因型变体进行匹配。Truvari的默认序列和大小相似阈值 $\geq 70\%$ 允许基因型者选择“不完美”但“合理”的变体表示来应用基因型。“pick ac”参数利用呼叫的基因型来确定它被允许参与多少匹配。例如,如果一个基因型赋予一个变体一个纯合子状态,它的等位基因数是两个,因此可以匹配最多两个基线变体。'no-ref a'参数忽略基线或比较vcf中缺失或参考纯合状态的变体。每个匹配且特鲁瓦里注释为GTMatch=0的基因型变异具有相同的基线基因型,并被归类为具有一致的基因型。每个匹配的变体,但与GTMatch!=0,每一个不匹配(即假阳性)的基因型变异被归类为具有不一致的基因型。因此,基因型一致性被定义为来自具有匹配变体和组合衍生变体中匹配基因型的基因型的当前呼叫(杂合或纯合交替)的百分比。

作为这个过程的一个例子,考虑一个基因座在VCF中有两个缺失,长度分别为105 bp和120 bp,并且从同一位置开始。该基因座上的预期/基线变异是110 bp的纯合子缺失,因此不存在“完美”的变异表示。Truvari的模糊性允许基因型者将纯合基因型分配给105 bp或120 bp的缺失,以获得正确的变异基因分型。然而,如果基因型将纯合子基因型分配给两个SV,则该工具将因不正确的基因型SV而受到惩罚。

通过串联重复序列重叠进行基因型表现的分层,将adotto TR目录v1.232亚组³⁸完全包含在一个装配的低常染色体高置信度区域内的TR区域,并且只有当SV的开始和结束边界发生在单个TR区域内时,才将其计数为在TR内。通过运行truvari anno numneigh对邻居数量进行基因型性能分层,其中注释了INFO字段“NumNeighbors”,指示基因型VCF中每个变体在1000 bp内的SVs数量。

测量计算性能

为了测量每个工具的单核性能,我们使用与1号染色体相关的12×CCS HG002 BAM的子集和32×CCS HG002 sniffles发现VCF的子集作为输入(我们使用samtools视图对BAM进行子集,使用samtools fastq对svjedii-graph进行相应的fastq,使用bcftools视图对VCF进行子集)。我们只使用了1号染色体作为参考。我们在每个工具的命令行上将线程数设置为1,并使用taskset命令将每个工具固定在我们机器的第五个逻辑核心上。我们使用/usr/bin/time测量时钟时间和最大常驻集大小(具体来说,我们对每个程序的五次迭代进行计时,将运行时度量除以五,并使用最大RSS度量)。对于minigraph,我们使用了打印在输出中的“Real time”和“Peak RSS”度量。

为了测量典型工作负载下的性能,我们在20倍CCS HG002 BAM和32倍CCS HG002 sniffles发现VCF上运行每个工具,在每个工具的命令行上将线程数设置为16,并将每个工具固定到逻辑核心8-23(都位于同一处理器上)。在这个实验中,我们只运行了SVJedigraph和pbmm2一次。

计算性能实验是在一台Ubuntu 20.04.4 LTS服务器(内核5.4.0)上运行的,该服务器配备了两个AMD Epyc 7513处理器(总共64个物理核)、500 GB RAM和一个NVMe SSD磁盘。没有其他用户或主要任务处于活动状态。

报告摘要

关于研究设计的更多信息可在本文链接的自然组合报告摘要中获得。

数据可用性

用于测试基因型³⁸的GRCh38上与dipcall对齐的HPRC组装所产生的结构变异已在zenodo上沉积,并附有登录代码(DOI:10.5281/zenodo.14726292) <https://zenodo.org/records/14726292> 先前发布的HPRC数据可通过https://anvil.terra.bio/#workspaces/anvil-datastorage/AnVIL_HPRC/data以及https://github.com/human-pangenomics/HPP_Year1_Data_Freeze_v1.0和https://github.com/human-pangenomics/HPP_Year1_Assemblies获得。先前发布的CARD ONT数据可在<https://console.cloud.google.com/storage/browser/fc-46bf051e-aec3-4adb-8178-3c51bc5e64ae>获得。

代码可用性

Kanpig在MIT许可下可在<https://github.com/ACEnglish/kanpig>获得。用于创建和总结这里呈现的结果的分析脚本和管道可以在github存储库https://github.com/fabio-cunial/kanpig_experiments/中获得。

参考资料

1. Coster, W. D., Weissensteiner, M. H. & Sedlazeck, F. J. Towards population-scale long-read sequencing. *Nat. Rev. Genet.* 22, 572–587 (2021).
2. Mahmoud, M. et al. Structural variant calling: the long and the short of it. *Genome Biol.* 20, 246 (2019).
3. Sudlow, C. et al. UK Biobank: an open access resource for identifying the causes of a wide range of complex diseases of middle and old age. *PLoS Med.* 12, e1001779 (2015).
4. Auton, A. et al. A global reference for human genetic variation. *Nature* 526, 68–74 (2015).
5. DePristo, M. A. et al. A framework for variation discovery and genotyping using next-generation DNA sequencing data. *Nat. Genet.* 43, 491–498 (2011).
6. English, A. C., Menon, V. K., Gibbs, R. A., Metcalf, G. A. & Sedlazeck, F. J. Truvari: refined structural variant comparison preserves allelic diversity. *Genome Biol.* 23, 271 (2022).
7. Chander, V., Gibbs, R. A. & Sedlazeck, F. J. Evaluation of computational genotyping of structural variation for clinical diagnoses. *Gigascience* 8, giz110 (2019).
8. Chiang, C. et al. SpeedSeq: ultra-fast personal genome analysis and interpretation. *Nat. Methods* 12, 966–968 (2015).
9. Ebler, J. et al. Pangenome-based genome inference allows efficient and accurate genotyping across a wide spectrum of variant classes. *Nat. Genet.* 54, 518–525 (2022).
10. Garrison, E. et al. Variation graph toolkit improves read mapping by representing genetic variation in the reference. *Nat. Biotechnol.* 36, 875–879 (2018).
11. Chen, S. et al. Paragraph: a graph-based structural variant genotyper for short-read sequence data. *Genome Biol.* 20, 291 (2019).
12. Zook, J. M. et al. A robust benchmark for detection of germline large deletions and insertions. *Nat. Biotechnol.* 38, 1347–1355 (2020).
13. Audano, P. A. et al. Characterizing the major structural variant alleles of the human genome. *Cell* 176, 663–675.e19 (2019).
14. Romain, S. & Lemaitre, C. SVJedi-graph: improving the genotyping of close and overlapping structural variants with long reads using a variation graph. *Bioinformatics* 39, i270–i278 (2023).
15. English, A. C. et al. Analysis and benchmarking of small and large genomic variants across tandem repeats. *Nat. Biotechnol.* 1–12. <https://doi.org/10.1038/s41587-024-02225-z> (2024).
16. Lance, G. N. & Williams, W. T. Computer programs for hierarchical polythetic classification (“Similarity Analyses”). *Comput. J.* 9, 60–64 (1966).

17. 10xGenomics, M. & 10xGenomics, M. Edlib: a C/C++ library for fast, exact sequence alignment using edit distance. *Bioinformatics* 33, btw753 (2016).
18. Zook, J. M. GIAB HG002 assembly-based small and structural variants draft benchmark sets. https://ftp-trace.ncbi.nlm.nih.gov/ReferenceSamples/giab/data/AshkenazimTrio/analysis/NIST_HG002_DraftBenchmark_defrabbV0.018-20240716/NIST_HG002_DraftBenchmark_defrabbV0.018-20240716_README_update.md (2024).
19. Liao, W.-W. et al. A draft human pangenome reference. *Nature* 617, 312–324 (2023).
20. Li, H. et al. A synthetic-diploid benchmark for accurate variant-calling evaluation. *Nat. Methods* 15, 595–597 (2018).
21. Smolka, M. et al. Detection of mosaic and population-level structural variants with Sniffles2. *Nat. Biotechnol.* 1–10. <https://doi.org/10.1038/s41587-023-02024-y> (2024).
22. Jiang, T. et al. Regentyping structural variants through an accurate force-calling method. Preprint at bioRxiv <https://doi.org/10.1101/2022.08.29.505534> (2023).
23. Danecek, P. et al. Twelve years of SAMtools and BCFtools. *Giga-science* 10, giab008 (2021).
24. Audano, P. A. & Beck, C. R. Small polymorphisms are a source of ancestral bias in structural variant breakpoint placement. *Genome Res.* <https://doi.org/10.1101/gr.278203.123> (2024).
25. Wenger, A. M. et al. Accurate circular consensus long-read sequencing improves variant detection and assembly of a human genome. *Nat. Biotechnol.* 37, 1155–1162 (2019).
26. Sereika, M. et al. Oxford Nanopore R10.4 long-read sequencing enables the generation of near-finished bacterial genomes from pure cultures and metagenomes without short-read or reference polishing. *Nat. Methods* 19, 823–826 (2022).
27. Kolmogorov, M. et al. Scalable nanopore sequencing of human genomes provides a comprehensive view of haplotype-resolved variation and methylation. *Nat. Methods* 20, 1483–1492 (2023).
28. Li, H., Feng, X. & Chu, C. The design and construction of reference pangenome graphs with minigraph. *Genome Biol* 21, 265 (2020).
29. Kirsche, M. et al. Jasmine and Iris: population-scale structural variant comparison and analysis. *Nat. Methods* 20, 408–417 (2023).
30. Li, H. Minimap2: pairwise alignment for nucleotide sequences. *Bioinformatics* 34, 3094–3100 (2018).
31. Beyter, D. et al. Long-read sequencing of 3,622 Icelanders provides insight into the role of structural variants in human diseases and other traits. *Nat. Genet.* 53, 779–786 (2021).
32. English, A. Project Adotto Tandem-Repeat Regions and Annotations. Preprint at <https://zenodo.org/records/8387564> (2022).
33. English, A. Kanpig Structural Variants Genotyping Benchmark from HPRC Dipcall. <https://zenodo.org/records/14726292> (2025).

致谢

作者要感谢Jason Chin对基于图的算法进行了富有成效的讨论, Yulia Mostovy对kanpig进行了早期的beta测试, Ryan Iorio - roach和Qihui Li在使用HPRC作为基准方面提供了意见, M

ichael Macias开发和支持了noodles-vcf rust crate, Xinchang Zheng对手稿进行了早期审查。以及Nathanael Olson和Justin Zook提前获得GIAB v1.1基准测试。本文得到了Baylor/JHU奖(OT2 OD002751 RG)、NIH奖(1U01HG011758-01 Posey)、All of Us奖(OT2 OD038121 gabriel Stacey)和Gabriella Miller Kids First奖(5U24HD090743 gabriel Stacey)的支持。

作者贡献

A.E.设计了项目并实施了kanpig。A.E.和联邦通信委员会进行了分析。a.e., f.c., g.m., r.g.和F.S.撰写了手稿。

利益竞争

FJS得到Illumina、PacBio和Oxford Nanopore的研究支持。其余作者声明无利益竞争。

附加信息

补充信息在线版本包含补充资料, 可在<https://doi.org/10.1038/s41467-025-58577-w>获取。

通信和索取材料应发送给Adam C. English。

同行评议信息Nature Communications感谢匿名审稿人对本文同行评议的贡献。可获取同行评议文件。

转载和权限信息可在<http://www.nature.com/reprints>获取

出版商施普林格《自然》杂志对已出版地图和机构从属关系中的管辖权主张保持中立。

开放获取本文遵循知识共享署名-非商业-非衍生品4.0国际许可协议, 该协议允许以任何媒介或格式进行非商业用途、共享、分发和复制, 只要您对原作者和来源给予适当的注明。提供知识共享许可协议的链接, 并注明您是否修改了许可材料。根据本许可协议, 您无权分享源自本文或其部分内容的改编材料。本文中的图像或其他第三方材料包含在本文的知识共享许可协议中, 除非在材料的署名中另有说明。如果材料未包含在文章的知识共享许可中, 并且您的预期用途不被法律法规允许或超过允许的用途, 您将需要直接获得版权所有者的许可。要查看此许可协议的副本, 请访问<http://creativecommons.org/licenses/by-nc-nd/4.0/>。

©作者2025